

Современные методы анализа данных и машинного обучения, БИ

НИУ ВШЭ, 2025-26 учебный год

Групповой проект №4. Statistics in Data Analysis

Общая информация

Дата выдачи: 06.05.2026

Дедлайн по записи в таблицу: 4:00 13.05.2026

Дедлайн по загрузке работ: 4:00 25.05.2026

Защита проекта: ~

Формат выполнения

Групповой проект представляет собой творческое инициативное групповое задание, которое выполняется студентами в командах от 3 до 6 человек. В то же время следует помнить, что чем больше в команде людей, тем выше предъявляются требования в целом к команде, а также к выполняемому ею проекту. Команды разрешается формировать из студентов разных групп.

При оценивании результатов выполнения проекта командой в обязательном порядке проверяется и учитывается в оценке вклад **каждого участника** в общую работу команды. Вследствие этого крайне важно ответственно подойти к выбору сокомандников, распределению обязанностей внутри команды, а также пресечению наличия "мертвых душ" в команде.

При необходимости команда большинством голосов имеет право исключить человека из команды **до загрузки работ** в систему [Anytask](#), сообщив об этом преподавателю, в случае если такой человек никак не проявлялся в ходе выполнения проекта и являлся как раз таки той самой "мертвой душой". Помните про эту возможность, поскольку наличие "мертвых душ" может негативно повлиять на качество и оценку для всего

проекта и, как следствие, в целом для всей команды!

Запись составов команд осуществляется по ссылке в таблице:

<https://docs.google.com/spreadsheets/d/1BfagrTqJr2VJ3pdps87VmsUCOZE49c0usp=sharing>

Отправка материалов группового проекта

Во избежание использования при выполнении группового проекта генеративных моделей (ChatGPT и так далее) за рамками справочной и образовательной информации (то есть, например, для автоматической генерации кода по одному из этапов) **одному из участников команды** необходимо предварительно загрузить работу в систему [Anytask](#).

Наличие сгенерированного кода или любого другого случая "несанкционированного" использования нейросетей будет считаться плагиатом, и такой проект будет оценен в 0 баллов для всех участников. При отсутствии своевременно загруженных файлов с проектом команде также выставляется 0 за проект.

Примечание: презентацию проекта загружать необязательно, важно отправить содержательные файлы с кодом

Оценивание и штрафы

Групповой проект оценивается исходя из устной защиты (презентации) командой выполненного ими проекта перед комиссией. Комиссия составляется из преподавателей курса, ассистентов курса, а также приглашенных экспертов из индустрии.

В рамках каждой защиты комиссия выставляет два типа оценок.

Первая оценка — это оценка для всего проекта в целом. Она ставится комиссией, исходя из глубины проработки командой предметной области, сложности применяемых в проекте инструментов, а также прочих аспектов, связанных с содержанием выполняемого в проекте ТЗ. При выставлении этой оценки комиссия ориентируется на критерии, более подробно представленные ниже в разделе "Критерии оценки проекта".

Вторая оценка — это индивидуальная оценка каждого участника команды. Именно эта оценка выставляется впоследствии в ведомость. Индивидуальная оценка участника команды определяется комиссией, исходя из того, насколько участник ориентируется в выполненном командой проекте, как он отвечает на адресованные персонально ему

вопросы комиссии, насколько в принципе прослеживается его роль в проекте, а также исходя из других аспектов, связанных с участием конкретного человека в деятельности команды. Индивидуальная оценка не может превосходить оценку команды за проект в целом (первую оценку), однако, в случае когда участник спокойно и корректно отвечает на все адресованные ему вопросы, свободно ориентируется в материале и содержании выполненного проекта, а также когда его роль в работе команды не вызывает сомнений, — в таком случае, индивидуальная оценка участника становится равной оценке для всего проекта (т.е. в идеальном случае — вторая оценка равна первой оценке). Кроме того, в исключительных случаях, при демонстрации участником на защите превосходящих ожидания уровней понимания, участия и вовлечения в рамках проекта, комиссия может своим решением повысить индивидуальную оценку для этого участника на 0,5 или 1 балл относительно общей оценки за проект (первой оценки).

Во избежание субъективности и/или предвзятости оценки тех или иных членов комиссии в отношении тех или иных команд, а также каких-либо иных проявлений неравных условий — распределение команд между комиссиями осуществляется абсолютно случайно с использованием средств библиотеки NumPy :) — в качестве рэндом сиду выступает дата, в которую производится распределение, например, `np.random.seed(14052026)`.

Обратите, пожалуйста, внимание на то, что большая часть комиссий осуществляет приём проектов в очной форме, однако могут присутствовать и 1-2 комиссии, которые будут работать дистанционно с использованием средств видеосвязи. В случае попадания команды путем случайного распределения в комиссию, работающую в очной форме, *не допускается* какое-либо изменение формата проведения для команды на онлайн-режим, равно как и любые другие перемещения команд между комиссиями (смены комиссий), для сохранения честности и непредвзятости случайного распределения.

Явка студента на защиту проекта является обязательной; вклад студента без его присутствия не оценивается и автоматически является равным нулю. Для дистанционных комиссий дополнительным требованием является обязательное наличие включенной камеры в течение всего времени нахождения в конференции

Описание задания

Практика A/B-тестирования, формирования и проверки статистических гипотез лежит в основе принятия решений в любой современной

компании, работающей с данными. Умение корректно провести эксперимент, проинтерпретировать результаты и сформулировать выводы непосредственно влияет на возможность роста продукта, сокращение издержек и уменьшение рисков.

Данный групповой проект состоит из **двух частей**:

1. **A/B-тестирование**: анализ результатов эксперимента, которые зафиксированы в датасете `data_ab.csv`, — проверка наличия статистически и практически значимых различий между наблюдениями в контрольной и экспериментальной группах.
2. **Проверка гипотез на выбранном датасете**: выбор одного или нескольких датасетов с сайта [UCI Machine Learning Repository](#) либо же получение соответствующих датасетов путем парсинга/работы с API; осуществление этапа первичного анализа данных (EDA); определение не менее трёх содержательных гипотез **на основе проделанного EDA**; их проверка с помощью различных статистических тестов.

Постановка задачи

Часть 1. A/B-тест

Для выполнения первой части группового проекта вам предоставляется датасет с результатами проведения некоторого A/B-тестирования в компании из сферы образования.

Датасет состоит из пяти столбцов:

- `user_id` — уникальный идентификатор пользователя;
- `timestamp` — время посещения пользователем страницы;
- `group` — группа эксперимента, к которой был случайно отнесён пользователь:
 - `control` — контрольная группа,
 - `treatment` — экспериментальная группа;
- `landing_page` — версия лендинга, которую увидел пользователь:
 - `old_page` — старая версия страницы,
 - `new_page` — новая версия страницы;
- `converted` — бинарный признак, показывающий, совершил ли пользователь целевое действие (целевым действием является регистрация на курс).

По замыслу A/B-теста контрольной группе (`control`) должна была показываться старая версия лендинга — `old_page` ; экспериментальной группе (`treatment`) должна была показываться новая версия лендинга — `new_page` .

Вам следует:

- понять структуру данных, провести EDA и выбрать метрику, с которой будете работать;
- проверить корректность проведения тестирования (посмотреть на однородность групп; задуматься об A/A-тесте; не забыть, что в нашем распоряжении есть еще и временные метки);
- сформулировать нулевую и альтернативную гипотезы на основании выбранной метрики;
- выбрать и обосновать статистический тест;
- решить, нужно ли устанавливать значения каких-либо параметров до начала анализа тестирования;
- оценить разницу в результатах и сделать выводы о практической значимости эксперимента;
- провести дополнительный анализ при необходимости (например, с помощью `bootstrap` или через анализ чувствительности);
- сформулировать рекомендации и бизнес-инсайты по результатам эксперимента.

Важно: это лишь возможные шаги для вашего исследования, и воспринимать их следует как подсказки. Ваша центральная задача в любом случае представлена в общем виде — осуществить качественный и полный анализ результатов проведенного A/B-тестирования.

Часть 2. Проверка гипотез методами математической статистики

В этой части группового проекта вам предстоит самим выбрать предметную область, а также самим получить датасет или датасеты, с которыми вы будете работать.

С точки зрения источников данных у вас есть две опции: вы можете найти ваш датасет — или 2-3 датасета в случае необходимости — на сайте [UCI Machine Learning Repository](#) (брать датасеты необходимо именно с этого сайта); либо же вторая опция — можно собрать датасет/датасеты вручную с помощью средств Parsing'a и API. Допускается использование и комбинации этих двух опций. В любом случае, **каждый** используемый вами датасет должен (до этапа EDA) содержать **не менее 2000 строк** и **не менее 8 признаков**.

После получения датасетов вам следует:

- провести EDA с осмысленными визуализациями и качественным поиском первичных закономерностей;
- на основе проделанного EDA сформулировать **минимум три чёткие, содержательные гипотезы**;
- подобрать и реализовать **минимум три различных статистических теста** для проверки сформулированных ранее гипотез, причём каждый тест должен быть обязательно обоснован (различные статистические тесты в нашем случае означает, что статистические критерии для этих тестов должны быть разными);
- корректно и полно проинтерпретировать полученные результаты и сформулировать итоговые выводы.

Важно: вы должны очень ответственно подойти к выбору датасета, так как гипотезы должны быть **не случайными**, а логически вытекающими из осуществленного EDA и, кроме того, имеющими реальный интерес для изучения и проверки с точки зрения бизнес-составляющей. В случае если по одному датасету у вас не получается сформировать 3 достаточно осмысленных гипотезы — разрешается использовать суммарно вплоть до 3 датасетов. В таком случае, все эти датасеты должны иметь какую-то связь между собой.

Общие требования к проекту

В качестве результата выполнения группового проекта ваша команда должна получить презентацию и защитить ее перед комиссией. Наличие репозитория с кодом на GitHub является необязательным условием, но приветствуется.

Оформление презентации остаётся полностью на ваше усмотрение, но помните, что результат должен быть релевантен для демонстрации бизнес-заказчику — комиссию, принимающую вашу работу, правильнее всего воспринимать именно в таком качестве. Например, вставлять в презентацию строчки кода или злоупотреблять скринами блокнота не рекомендуется.

С точки зрения концепции выполнения проекта — вам необходимо принять на себя роль дата-аналитиков: продемонстрировать способность грамотно работать с экспериментальными статистическими данными, что включает в себя проверку корректности проведения и интерпретацию результатов построенного A/B-тестирования, правильную формулировку гипотез, выбор подходящих статистических методов, моделей и их параметров, а также построение итоговых выводов из анализа — и исследователей: уметь выбирать релевантный датасет, проводить содержательный EDA, находить закономерности и

превращать их в осмысленные статистические гипотезы для проверки. А в конце, конечно, — презентовать всю эту красоту в понятном виде потенциальному заказчику.

Подчеркнём отдельно: ваша задача — не просто провести тесты и сделать какие-то выводы из них, но разобраться в данных, изучить их природу, выявить реальные зависимости и инсайты, а также на основе проделанного анализа показать, почему эти находки важны для бизнеса или для выбранного контекста датасета. Разумеется, чем интереснее выбранная вами предметная область, чем осмысленнее сформулированные гипотезы и чем глубже будет проведенное вами исследование — тем выше окажется итоговое качество проекта и тем выше он будет оценён!

Полезные замечания и советы

- Графики и визуализации помогают наглядно доносить информацию, а также анализировать данные
- Формулируйте гипотезы *после* EDA. Не придумывайте гипотезы "вслепую", сначала погрузитесь в данные, найдите закономерности, паттерны и лишь затем переходите к выделению статически проверяемых гипотез
- Не забывайте о прикладной значимости ваших проектов — ваш анализ должен быть полезен потенциальному заказчику
- Используйте разные подходы к проверке гипотез. Ищите способы усилить ваши тесты. Применяйте новые методы и идеи, а затем рассказывайте про них нам. Не бойтесь экспериментировать! Это будет только поощряться :)

Критерии оценки проекта

Оценка за групповой проект в целом — то есть первая из двух оценок — выставляется по 10 балльной шкале, исходя из 3 критериев. Также комиссия на своё усмотрение может добавить (но не снизить) некоторое количество бонусных баллов за рамками данных критериев.

Каждый из критериев будет перечислен и рассмотрен ниже.

Критерий 1. Анализ результатов A/B-тестирования (до 3,5 баллов)

Данный критерий оценивает качество, глубину и корректность проведенного анализа результатов A/B-тестирования, включая выбор

метрики, оценку реализации теста, а также спектр статистических методов и их обоснованность, формулирование гипотез и выводов по проделанному исследованию.

*По данному критерию можно получить **1 балл и выше** только при условии осмысленного осуществления этапа EDA, корректного выбора метрики, верной формулировки гипотез, обоснованного проведения статистического теста и правильной интерпретации полученных результатов.*

*По данному критерию можно получить **2 балла и выше** только при условии учёта в значительной степени временной составляющей эксперимента.*

*По данному критерию можно получить **3 балла и выше** только при условии обоснованного применения дополнительных инструментов/подходов для анализа результатов A/B-тестирования, не упомянутых ранее в этом ноутбуке и не рассматривавшихся в рамках соответствующего семинара и лекции (bootstrap'a или анализа чувствительности может хватить на 3 балла при условии корректного и осмысленного их применения).*

Критерий 2. Выбор предметной области и датасета, EDA, формулирование гипотез (до 3 баллов)

Данный критерий оценивает, насколько обоснованными и осмысленными получились сформулированные вами гипотезы на основании проведенного EDA по выбранной вами второй предметной области и датасетам, связанным с ней.

Важно: в случае оценки **0 баллов** за этот критерий оценка за следующий критерий также становится равна нулю.

*По данному критерию нельзя получить **больше 0 баллов** при отсутствии 3 сформулированных по датасету или связанным друг с другом датасетам, гипотез, имеющих **разную природу**.*

*По данному критерию нельзя получить **больше 0 баллов** при условии, что хотя бы один используемый в проекте датасет не удовлетворяет требованиям, описанным в разделах выше.*

*По данному критерию можно получить **1 балл и выше** только при условии осмысленного осуществления этапа EDA и наличия 3 гипотез, напрямую логически вытекающих из этого этапа.*

Критерий 3. Проведение статистических тестов по

выбранной предметной области (до 3,5 баллов)

Данный критерий оценивает качество статистического анализа, корректность выбора тестов, разнообразие использованных статистических инструментов, интерпретацию результатов и глубину полученных выводов.

*По данному критерию можно получить **1 балл и выше** только при условии корректного использования трех различных статистических тестов.*

*По данному критерию можно получить **2 балла и выше** только при условии полностью обоснованного (и правильного) выбора каждого из используемых статистических тестов.*

*По данному критерию можно получить **3 балла и выше** только при условии проведения сравнительного анализа нескольких тестов друг с другом хотя бы для одной гипотезы, а также осмысленной интерпретации проделанного анализа в контексте реальной исследовательской задачи.*